Tugas Reinforcement Learning: Q-Learning

Environment "Drone Pengantar Obat"

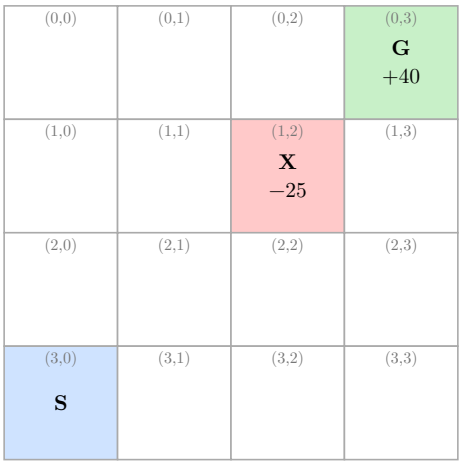
Nama	Benedictus Ryu Gunawan
NRP	5054251001

1. Ringkasan Environment

Grid 4×4 dengan koordinat (baris, kolom), baris 0 paling atas. Start $(3, 0)$, goal $(0, 3)$ dengan reward $+40$ (terminal), obstacle $(1, 2)$ dengan reward -25 (terminal). Langkah biasa bernilai -1, menabrak batas area bernilai -3 dan drone tetap di petak semula. Parameter: $\alpha = 0.4$, $\gamma = 0.9$, semua Q awal $= 0$.

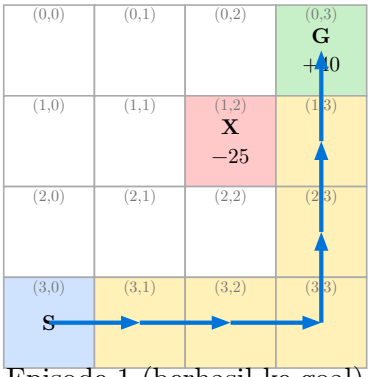
$$Q(s, a) \leftarrow Q(s, a) + \alpha \Big[r + \gamma \cdot \max_{a'} Q(s', a') - Q(s, a) \Big]$$

dengan $\max Q(s', \cdot) = 0$ jika s' terminal.

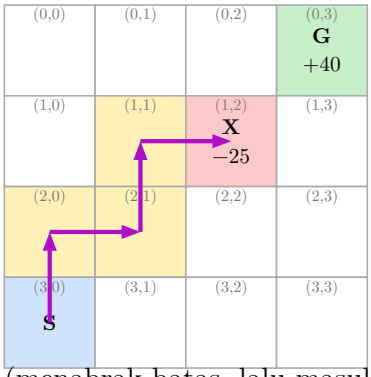


Gambar 1: Peta environment. **S** = start (gudang farmasi), **G** = goal (IGD), **X** = obstacle.

Q-value yang sudah dipelajari dari Episode 1 dan 2 (selain yang tercantum, nilainya 0):



Episode 1 (berhasil ke goal)



Episode 2 (menabrak batas, lalu masuk obstacle)

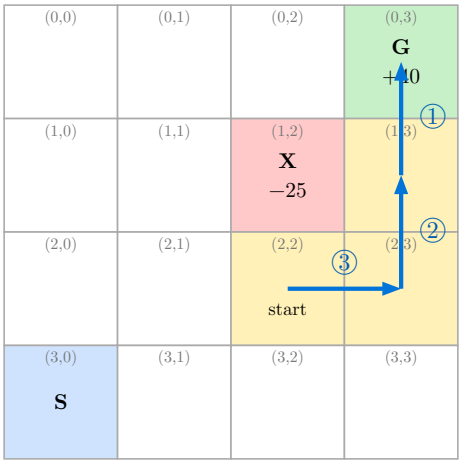
Gambar 2: Lintasan Episode 1 dan Episode 2.

Episode 1		
State	**Action**	**Q**
(1,3)	↑	16
(3,0)	→	−0.4
(3,1)	→	−0.4
(3,2)	→	−0.4
(3,3)	↑	−0.4
(2,3)	↑	−0.4

Episode 2		
State	**Action**	**Q**
(3,0)	↑	−0.4
(2,0)	←	−1.2
(2,0)	→	−0.4
(2,1)	↑	−0.4
(1,1)	→	−10

2. Episode 3 (Backward Update)

Path: $(2,2) \xrightarrow{\rightarrow} (2,3) \xrightarrow{\uparrow} (1,3) \xrightarrow{\uparrow} (0,3)$. Pembaruan dilakukan mundur, dimulai dari langkah terakhir yang mencapai goal, sehingga nilai goal langsung "mengalir" ke state sebelumnya.



Gambar 3: Lintasan Episode 3. Urutan update backward:①$Q((1,3),\uparrow)$,②$Q((2,3),\uparrow)$,③$Q((2,2),\rightarrow)$.

2.1. (a) $Q((1,3),\uparrow)$

Transisi $(1,3) \xrightarrow{\uparrow} (0,3)$: $r = +40$, $s' = (0,3)$ terminal sehingga $\max Q(s',\cdot) = 0$. Nilai lama $Q((1,3),\uparrow) = 16$.

$$\begin{aligned} Q((1,3),\uparrow) &= 16 + 0.4[40 + 0.9 \cdot 0 - 16] \\ &= 16 + 0.4 \cdot 24 \\ &= 16 + 9.6 = \mathbf{25.6} \end{aligned}$$

2.2. (b) $Q((2,3),\uparrow)$

Transisi $(2,3) \xrightarrow{\uparrow} (1,3)$: $r = -1$. Nilai lama $Q((2,3),\uparrow) = -0.4$. Karena update backward, $\max Q((1,3),\cdot)$ memakai hasil (a):

$$\max_{a'} Q((1,3),a') = \max(25.6, 0, 0, 0) = 25.6$$

$$\begin{aligned} Q((2,3),\uparrow) &= -0.4 + 0.4[-1 + 0.9 \cdot 25.6 - (-0.4)] \\ &= -0.4 + 0.4[-1 + 23.04 + 0.4] \\ &= -0.4 + 0.4 \cdot 22.44 \\ &= -0.4 + 8.976 = \mathbf{8.576} \end{aligned}$$

2.3. (c) $Q((2,2),\rightarrow)$

Transisi $(2,2) \xrightarrow{\rightarrow} (2,3)$: $r = -1$. $Q((2,2),\rightarrow)$ belum pernah diperbarui, jadi nilai lamanya 0. Dari hasil (b):

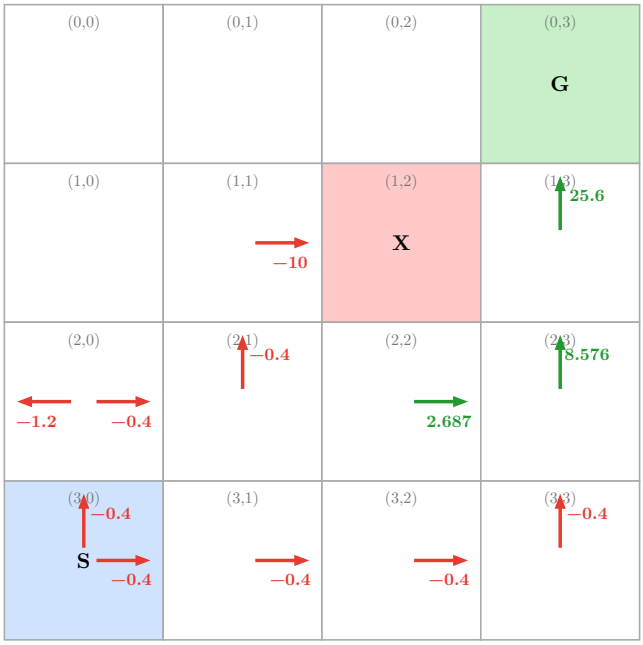
$$\max_{a'} Q((2,3),a') = \max(8.576, 0, 0, 0) = 8.576$$

$$\begin{aligned} Q((2,2),\rightarrow) &= 0 + 0.4[-1 + 0.9 \cdot 8.576 - 0] \\ &= 0.4[-1 + 7.7184] \\ &= 0.4 \cdot 6.7184 = \mathbf{2.68736} \approx \mathbf{2.687} \end{aligned}$$

Langkah	Q(s,a)	Sebelum	Sesudah
①	$Q((1,3),\uparrow)$	16	**25.6**
②	$Q((2,3),\uparrow)$	-0.4	**8.576**
③	$Q((2,2),\rightarrow)$	0	**2.687**

3. Analisis Policy

Gambar berikut menunjukkan semua Q-value yang bukan nol setelah Episode 3. Panah hijau berarti Q positif (menuju goal), panah merah berarti Q negatif.



Gambar 4: Peta Q-value setelah Episode 3 (action yang tidak digambar bernilai 0).

Dari state (1,1): hindari action → (kanan).
$Q((1,1),\rightarrow) = -10$, nilai paling kecil di state ini (action lain masih 0). Action → membawa drone ke $(1,2)$, yaitu obstacle: drone mendarat darurat dengan reward -25 dan episode berakhir tanpa mencapai goal. Nilai $-10 = 0 + 0.4(-25 + 0 - 0)$ adalah sinyal penalti terbesar di seluruh Q-table.

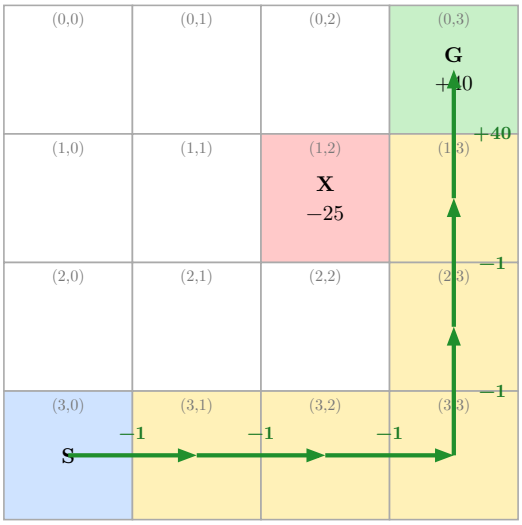
Dari state (2,0): hindari action ← (kiri).
$Q((2,0),\leftarrow) = -1.2$, lebih buruk daripada $Q((2,0),\rightarrow) = -0.4$ dan action lain (0). Kolom 0 adalah batas kiri area, jadi ← membuat drone menabrak batas: reward -3 dan drone tetap di $(2,0)$. Langkah ini membuang energi dan waktu tanpa kemajuan: $-1.2 = 0 + 0.4(-3 + 0.9 \cdot 0 - 0)$.

Dari state (2,3): action terbaik adalah ↑ (atas).
$Q((2,3),\uparrow) = 8.576$, satu-satunya nilai positif di state ini (action lain 0). Action ↑ membawa drone ke $(1,3)$, dan dari sana ↑ sekali lagi mencapai goal ($Q((1,3),\uparrow) = 25.6$). Jadi $\arg\max_a Q((2,3),a) = \uparrow$, yang berarti hanya 2 langkah lagi ke IGD dan tidak melewati obstacle.

4. Jalur Optimal

Jarak Manhattan dari $(3,0)$ ke $(0,3)$ adalah $3+3=6$ langkah, jadi jalur optimal minimal 6 langkah tanpa menabrak batas dan tanpa melewati $(1,2)$. Jalur yang sesuai dengan Q-value yang sudah dipelajari (Episode 1 dan 3) adalah:

$$(3,0) \xrightarrow{\rightarrow} (3,1) \xrightarrow{\rightarrow} (3,2) \xrightarrow{\rightarrow} (3,3) \xrightarrow{\uparrow} (2,3) \xrightarrow{\uparrow} (1,3) \xrightarrow{\uparrow} (0,3)$$



Gambar 5: Jalur optimal $(3,0) \rightarrow (0,3)$ beserta reward setiap langkah. Obstacle $(1,2)$ tidak dilewati.

Total reward (tanpa diskon):

Langkah	Transisi	Action	Reward
1	(3,0) → (3,1)	→	−1
2	(3,1) → (3,2)	→	−1
3	(3,2) → (3,3)	→	−1
4	(3,3) → (2,3)	↑	−1
5	(2,3) → (1,3)	↑	−1
6	(1,3) → (0,3)	↑	+40
Total			**+35**

$$G = 5 \times (-1) + 40 = -5 + 40 = \mathbf{35}$$

Catatan: langkah terakhir hanya diberi reward goal +40 (sesuai Episode 1, di mana $Q((1,3),\uparrow) = 0.4 \cdot 40 = 16$). Jalur 6 langkah lain yang tidak melewati $(1,2)$, misalnya $\uparrow\uparrow\uparrow\rightarrow\rightarrow\rightarrow$ lewat baris 0, juga menghasilkan total 35. Namun jalur di atas adalah jalur yang dipilih secara greedy oleh Q-table saat ini, karena hanya jalur ini yang sudah memiliki Q positif menuju goal.